

一、轻量化部署方向工作总结

1、研究动机

在前期实验中，基于 RAFT-Stereo 的 refinement head、边缘感知损失以及 partial unfreeze 等改进方法，并未在 Middlebury 数据集上取得稳定、显著的精度提升，说明原始 raftstereo-middlebury 模型本身已经具有较强性能，小规模真实域数据下难以通过小幅结构改动进一步提升整体指标。

因此，后续工作将研究重点由“继续提升精度”转向“在尽量保持精度的前提下降低模型部署开销”，即探索 RAFT-Stereo 在边缘设备上的轻量化部署方案。

2、轻量化研究思路

本阶段主要围绕以下两个方向展开：

(1)、官方轻量模型对比：realtime 版本

首先，选择官方提供的 raftstereo-realtime.pth 作为轻量化基线模型，与高精度的 raftstereo-middlebury.pth 进行对比。该模型通过减少网络规模、降低迭代次数、共享部分骨干结构等方式提升实时性，目标是在更低资源消耗下完成双目匹配任务。

这一实验的目的在于验证：直接采用官方轻量模型，是否能够在保证可接受精度的前提下实现部署端优化。

(2)、半精度部署：FP16

在发现 realtime 模型精度下降较明显后，进一步尝试 FP16 半精度部署方案。该方案不改变原始 RAFT-Stereo 网络结构，也不重新训练模型，而是直接将高精度的 raftstereo-middlebury.pth 转换为半精度权重模型，并在推理与评测阶段采用 FP16 进行部署测试。

这一方案的核心思想是：

- 保留原始高精度模型结构；
- 避免重新训练带来的额外成本；
- 通过降低数值精度减少模型文件大小、显存占用和推理时间；
- 在尽量保持原始精度的前提下，实现更适合边缘设备的部署形式。

3、实验设置

(1)、模型与环境

项目	设置
高精度基线模型	RAFT-Stereo (raftstereo-middlebury.pth)
轻量化对照模型	RAFT-Stereo Realtime (raftstereo-realtime.pth)
半精度模型	RAFT-Stereo FP16 (raftstereo-middlebury-fp16.pth)
推理设备	GPU：NVIDIA 4090

项目	设置
correlation	reg

(2)、对比方案

本阶段主要设置了三组对比：

- **Baseline FP32**：原始 `raftstereo-middlebury.pth`
- **Realtime**：官方轻量化实时模型 `raftstereo-realtime.pth`
- **FP16**：由 `raftstereo-middlebury.pth` 转换得到的半精度模型 `raftstereo-middlebury-fp16.pth`

(3)、评价维度

为了从部署角度评价模型轻量化效果，本阶段不仅关注匹配精度，还额外统计了以下指标：

- **EPE**：平均像素误差
- **D1**：离群点比例
- **模型大小**：模型文件存储开销
- **Average Inference Time**：平均推理时间
- **FPS**：每秒处理帧数
- **Max CUDA Memory Allocated**：推理阶段显存占用峰值

4、实验结果

(1)、官方 realtime 模型与高精度模型对比

模型	参数量	EPE	D1
RAFT-Stereo Middlebury	11.14M	2.3758	12.0526
RAFT-Stereo Realtime	9.89M	11.1557	28.5460

从结果可以看出，官方 realtime 模型参数量相较于高精度 Middlebury 模型有所减少，但在 Middlebury2014 数据集上的精度下降非常明显：

- EPE 由 **2.3758** 上升到 **11.1557**
- D1 由 **12.0526** 上升到 **28.5460**

这说明：**直接采用官方轻量模型虽然能够降低模型规模，但会带来较大的精度损失，不适合作为当前任务的最终部署方案。**

(2) FP16 半精度部署结果

模型	EPE	D1	平均推理时间	FPS	最大显存占用	模型大小
Baseline FP32	2.3758	12.0526	209.80 ms	4.77	844.91 MB	43 MB

模型	EPE	D1	平均推理时间	FPS	最大显存占用	模型大小
FP16	2.3535	12.0593	173.59 ms	5.76	662.34 MB	22 MB


进一步计算可得：

- **模型大小**：43 MB → 22 MB，下降约 **48.8%**
- **显存占用**：844.91 MB → 662.34 MB，下降约 **21.6%**
- **平均推理时间**：209.80 ms → 173.59 ms，缩短约 **17.3%**
- **FPS**：4.77 → 5.76，提升约 **20.8%**

而在精度方面：

- **EPE**：2.3758 → 2.3535，基本保持一致
- **D1**：12.0526 → 12.0593，几乎不变

这说明：将高精度 Middlebury 模型直接转换为 FP16 半精度模型后，模型精度基本保持稳定，同时明显降低了模型存储、显存占用和推理时间。



5、结果分析

通过本阶段实验，可以得到如下分析：

a、官方 realtime 轻量模型存在明显精度代价

虽然 realtime 模型在参数量上比高精度 Middlebury 模型更小，但在 Middlebury2014 数据集上的 EPE 和 D1 均大幅恶化，说明这种结构级轻量化方式是以显著牺牲匹配精度为代价实现的。

b FP16 半精度部署是一种更稳妥的轻量化方式

与直接更换轻量模型不同，FP16 方案不改变原始网络结构，因此保留了高精度模型已经学习到的匹配能力。实验表明，在几乎不损失精度的情况下，FP16 能够显著减小模型文件体积，并降低显存和时间开销。

c、对于当前任务，部署优化比结构替换更合适

结合前面对 refinement 系列方法和 realtime 模型的实验可以看出，对于 Middlebury 这种偏高精度需求的双目匹配任务，直接替换为更小的轻量结构往往会带来较大精度损失；相比之下，在保持主模型结构不变的基础上做半精度部署，更适合作为当前阶段的轻量化方案。

6、实验结论

通过本次轻量化部署实验，可以得到以下结论：

- 官方 `raftstereo-realtime` 模型虽然在参数规模上更小，但在 Middlebury2014 数据集上的精度下降明显，难以满足高精度双目匹配任务需求；
 - 基于 `raftstereo-middlebury.pth` 的 **FP16 半精度部署方案**，在不改变原始模型结构、也不重新训练的前提下，实现了模型体积、显存占用和推理时间的有效下降；
 - FP16 模型在 EPE 和 D1 指标上与原始 FP32 模型基本保持一致，说明其能够在较好保留模型性能的同时降低部署开销；
 - 相较于直接采用官方轻量化结构，**FP16 半精度部署是一种更适合当前任务场景的轻量化方法**；
 - 该方法工程实现成本较低，部署路径清晰，具有进一步面向边缘设备应用的可行性。
-

7、后续规划

后续可以继续围绕以下方向展开：

- 在 FP16 部署基础上，进一步补充不同输入分辨率下的推理速度与显存测试；
- 尝试在 Jetson 等边缘硬件平台上验证实际部署效果；
- 进一步探索剪枝、蒸馏等轻量化方法，与 FP16 方案形成对比；
- 在保持精度的前提下，研究更适合嵌入式或低功耗场景的双目匹配部署策略。